

## Raport z zajęć nr 5

### Zad.1

Celem zadania jest zapoznanie się z działaniem toolboxa i prezentacja jego możliwości dla wybranych funkcji:


- a) Aproksymująca
- b) Interpolująca
- c) Smoothing

#### a) Aproksymująca

Zestaw danych użyty do zadania:


```
1 - clc; close all; clear;  
2  
3 - x = [1:13];  
4 - y = [-4,8,12,10,4,2,-12,-2,-13,0,3,3,5];  
5
```

Funkcja wyznaczona dla wielomianu pierwszego stopni:




$$f(x) = -1.605 \cdot x + 1.231$$

Funkcja wyznaczona dla wielomianu drugiego stopni:



$$f(x) = 2.886 \cdot x^2 - 1.605 \cdot x - 1.434$$


Funkcja wyznaczona dla wielomianu czwartego stopni:




Zgodnie z naszymi oczekiwaniami funkcje wyznaczone dla wielomianów wyższych stopni lepiej reprezentują rozmieszczenie punktów.

### b) Interpolująca

Interpolacja metodą Cubic:




Interpolacja metodą Nearest neighbor:




Dla naszego zestawu danych metoda Cubic okazała się lepsza niż Nearest neighbor.

### c)Smoothing


Smoothing dla parametru  $p = 0.99812239$ :



Smoothing dla parametru  $p = 0.90685918$ :



Smoothing dla parametru  $p = 0.3264852$ :



Widzimy ,że zmniejszanie parametru  $p$  (Smoothing parameter) powoduje wypłaszczenie się naszego wykresu.

## Zad.2

Celem zadanie jest aproksymacja zestawu danych przy pomocy funkcji polyfi dla wielomianów stopnia pierwszego ,trzeciego i piątego.

Zestaw danych użyty do zadania:

```
clc; close all; clear;
```


```
x = [1:13];
```

```
y = [-4,8,12,10,4,2,-12,-2,-13,0,3,3,5];
```

```
xpol = [0:0.1:13];
```

Jest to dokładnie ten sam zestaw danych który został użyty w zadaniu nr 1.

Reprezentacja wyników aproksymacji:



wielomian pierwszego stopnia:  $-0.4121x + 4.1154$

wielomian trzeciego stopnia:  $0.1072x^3 - 2.0614x^2 + 10.0052x - 7.2378$

wielomian piątego stopnia:

$-0.0010x^5 + 0.0035x^4 + 0.5496x^3 - 7.7894x^2 + 32.1236x - 29.0944$

Widzimy ,że podobnie jak w zadaniu pierwszym im większy stopień wielomiany tym funkcja jet bardziej dopasowana do naszego zestawu danych.

### Zad.3

Celem zadania jest przedstawienie zjawiska overfittingu.

Zestawy danych użyte do zadania:

Dla sześciu punktów:

```
x = [1:6];  
y = (rand(1,6)*10);
```

Dla dziesięciu punktów:

```
x = [1:10];  
y = (rand(1,10)*10);
```

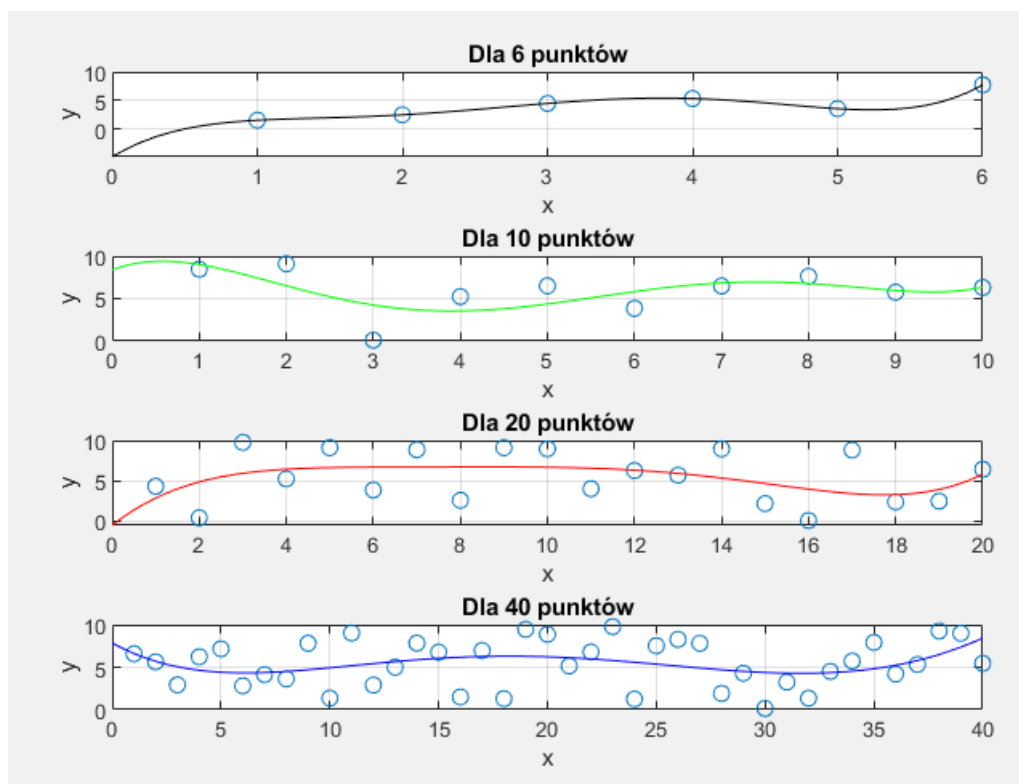
Dla dwudziestu punktów:

```
x = [1:20];  
y = (rand(1,20)*10);
```

Dla czterdziestu punktów:

```
x = [1:40];  
y = (rand(1,40)*10);
```

Przedstawienie wyników aproksymacji na wykresach:



Wyraźnie widzimy, że dla względnie dużej liczby punktów (20, 40) przybliżony wykres funkcji nie pokrywa się z punktami, odchylenia punktów są znaczące. Spowodowane to jest zjawiskiem overfittingu, które powoduje, że dla małego zakresu danych aproksymacja jest w stanie bardzo dokładnie przybliżyć funkcję dla danych punktów, jednak gdy ilość danych zwiększa się, nie ma możliwości odpowiedniego dopasowania.

### Zad.4

Celem ćwiczenia jest implementacja własnych algorytmów aproksymujących:


- a) Metodą liniową
- b) Metodą potęgowa
- c) Metodą wykładniczą

#### a) Metodą liniową

Zestaw danych użyty do zadania:

```
x = [1:13];  
y = [-4, 8, 12, 10, 4, 2, -12, -2, -13, 0, 3, 3, 5];  
xpol = [1:0.1:13];
```

Reprezentacja wyniku aproksymacji:




Widzimy, że wynik działania naszego algorytmu pokrywa się z wynikiem działania wbudowanych funkcji Matlaba.

## b)Metoda potęgowa + c)Metoda wykładnicza

Zestaw danych użyty do zadania:


```
x = [1:13];  
y = [1,5,10,4,6,12,18,14,10,20,21,22,23];  
xpol = [0:0.1:13];
```

Reprezentacja wyników aproksymacji:




Porównujemy nasze wyniki z działaniem cftoola:

### Aproksymacja potęgowa



## Aproksymacja wykładnicza:




### Zad.5

Celem zadania jest wyznaczenie błędu średniokwadratowego na podstawie metod z zadania czwartego przy użyciu cftoola:

- a) MSE dla aproksymacji liniowej
- b) MSE dla aproksymacji potęgowej
- c) MSE dla aproksymacji wykładniczej

#### a) MSE dla aproksymacji liniowej



$$RMSE = \sqrt{MSE}$$

$$MSE = RMSE^2$$

$$MSE = 10,65$$

#### b) MSE dla aproksymacji potęgowej

General model Power1:

$$f(x) = a \cdot x^b$$

Coefficients (with 95% confidence bounds):

$$a = 1.988$$
 (0.1415, 3.835)

$$b = 0.9582$$
 (0.5516, 1.365)

$$MSE = 10,67$$

Goodness of fit:

SSE: 117.4

R-square: 0.8264

Adjusted R-square: 0.8106

RMSE: 3.267



c) MSE dla aproksymacji wykładniczej

General model Exp1:

$$f(x) = a \cdot \exp(b \cdot x)$$

Coefficients (with 95% confidence bounds):

a = 4.582 (2.072, 7.093)

b = 0.131 (0.07897, 0.1831)

MSE = 12,62

Goodness of fit:

SSE: 138.8

R-square: 0.7947

Adjusted R-square: 0.7761

RMSE: 3.552

Jak widzimy dla naszego zestawu danych największy błąd średniokwadratowy występuje dla aproksymacji wykładniczej. MSE w aproksymacji liniowej i potęgowej są bardzo zbliżone, jednak najdokładniejsze przybliżenie daje aproksymacja liniowej.